

# SVD—矩阵奇异值分解 —— 原理与几何意义

## 1 简介

SVD 全称: Singular Value Decomposition。SVD 是一种提取信息的强大工具, 它提供了一种非常便捷的矩阵分解方式, 能够发现数据中十分有意思的潜在模式。

主要应用领域包括:

- 隐性语义分析 (Latent Semantic Analysis, LSA) 或隐性语义索引 (Latent Semantic Indexing, LSI);
- 推荐系统 (Recommender system), 可以说是最有价值的应用点;
- 矩阵形式数据 (主要是图像数据) 的压缩。

## 2 线性变换

在做 SVD 推导之前, 先了解一下线性变换, 以  $2 \times 2$  的线性变换矩阵为例, 先看简单的对角矩阵:

$$M = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$$

从集合上讲,  $M$  是将二维平面上的点  $(x, y)$  经过线性变换到另一个点的变换矩阵, 如下所示:

$$\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3x \\ y \end{bmatrix}$$

该变换的几何效果是, 变换后的平面沿着  $x$  水平方向进行了3倍拉伸, 垂直方向没有发生变化。

## 3 SVD 推导

该部分的推导从几何层面上去理解二维的SVD, 总体的思想是: 借助 SVD 可以将一个相互垂直的网格 (orthogonal grid) 变换到另外一个互相垂直的网格。

可以通过二维空间中的向量来描述这件事情。

首先, 选择两个互相正交的单位向量  $\mathbf{v1}$  和  $\mathbf{v2}$  (也可称为一组正交基)。

$M$  是一个变换矩阵。

向量  $M\mathbf{v1}$ ,  $M\mathbf{v2}$  也是一组正交向量 (也就是  $\mathbf{v1}$  和  $\mathbf{v2}$  经过  $M$  变换得到的)。

$\mathbf{u1}$ ,  $\mathbf{u2}$  分别是  $M\mathbf{v1}$ ,  $M\mathbf{v2}$  的单位向量 (即另一组正交基), 且有:

$$Mv_1 = \sigma_1 u_1$$

$$Mv_2 = \sigma_2 u_2$$

则， $\sigma_1, \sigma_2$  分别为  $Mv_1, Mv_2$  的模（也称为M的奇异值）。

设任意向量x，有：

$$x = (v_1 \cdot x)v_1 + (v_2 \cdot x)v_2$$

$$x = (v_1 \cdot x)v_1 + (v_2 \cdot x)v_2$$

例如，当  $x = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$  时， $x = \left( \begin{bmatrix} 1 \\ 0 \end{bmatrix} [3 \ 2] \right) \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \left( \begin{bmatrix} 0 \\ 1 \end{bmatrix} [3 \ 2] \right) \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 。

那么，可得：

$$Mx = (v_1 \cdot x)Mv_1 + (v_2 \cdot x)Mv_2$$

$$Mx = (v_1 \cdot x)\sigma_1 u_1 + (v_2 \cdot x)\sigma_2 u_2$$

根据线代知识，向量的内积可用向量的转置来表示：

$$v_1 \cdot x = v_1^T x, \text{ 则有：}$$

$$Mx = v_1^T x \sigma_1 u_1 + v_2^T x \sigma_2 u_2$$

两边去掉  $x$ ，得：

$$M = u_1 \sigma_1 v_1^T + u_2 \sigma_2 v_2^T$$

将下标相同的向量合并起来，则该式可通用地表达为：

$$M = U \Sigma V^T$$

至此，SVD 使用几何意义的形式推导完毕，其中：

- $U$  矩阵的列向量分别是  $u_1, u_2$  ；
- $\Sigma$  是一个对角矩阵，形如：
$$\begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix}$$
 ；
- $V$  矩阵的列向量分别是  $v_1, v_2$  。

#### 关于 SVD 的一些重要的结论性总结：

- 任意的矩阵 $M$ 是可以分解成三个矩阵；
- $V$ 表示了原始域的标准正交基；
- $U$ 表示经过 $M$ 变换后的新标准正交基；
- $\Sigma$ 表示了 $V$ 中的向量与 $U$ 中相对应向量之间的比例（伸缩）关系；
- $\Sigma$ 中的每个 $\sigma$ 会按从大到小排好顺序，值越大代表该维度重要性越高；
- 在利用 SVD 做数据信息提取或压缩时，往往依据一些启发式策略，如直接设定只提取 $\Sigma$  中的前  $k$  项，或者另一种较常用的做法是保留矩阵中一定百分比的能量信息，一般可设定为 90%，能量信息比例的计算可先求得所有奇异值平方总和，然后将奇异值的平方依次累加到总值的 90% 为止，形如：

$$k = \arg \min_k \frac{\sum_{i=0}^k \sigma_i^2}{\sum_{i=0}^N \sigma_i^2} \geq 0.9 .$$

# -\*- coding: utf-8 -\*-

```
import numpy as np
import numpy.linalg as la
import matplotlib.pyplot as plt
from sklearn import datasets
from skimage import io

def getImgAsMat(index):
    ds = datasets.fetch_olivetti_faces()
    return np.mat(ds.images[index])
```

```
def getImgAsMatFromFile(filename):  
    img = io.imread(filename, as_grey=True)  
    return np.mat(img)
```

```
def plotImg(imgMat):  
    plt.imshow(imgMat, cmap=plt.cm.gray)  
    plt.show()
```

```
def recoverBySVD(imgMat, k):  
    # singular value decomposition  
    U, s, V = la.svd(imgMat)  
    # choose top k important singular values (or eigens)  
    Uk = U[:, 0:k]  
    Sk = np.diag(s[0:k])  
    Vk = V[0:k, :]  
    # recover the image  
    imgMat_new = Uk * Sk * Vk  
    return imgMat_new
```

```
# ----- main ----- #
```

```
#A = getImgAsMat(0)  
#plotImg(A)  
#A_new = recoverBySVD(A, 20)  
#plotImg(A_new)
```

```
A = getImgAsMatFromFile('D:/pic.jpg')  
plotImg(A)  
A_new = recoverBySVD(A, 30)  
plotImg(A_new)
```

## 5 参考资料

1. We Recommend a Singular Value Decomposition (AMS 上一篇非常经典的关于SVD几何意义的介绍)
2. 奇异值分解 (SVD) 的几何意义中文翻译

作者：张磊 机器学习爱好者

知乎：[https://zhuanlan.zhihu.com/c\\_184412713](https://zhuanlan.zhihu.com/c_184412713)